Presentasi UTS Machine Learning

# Classification Model

Presented by Anita Firda N (1103213117)

### Import library

Berbagai macam library yang digunakan

[73] !pip install xgboost

import pandas as pd #Untuk membaca dan menulis data dari berbagai format file.
import matplotlib.pyplot as plt #Untuk membuat plot dan visualisasi.
import seaborn as sns #Untuk visualisasi data statistik, membuat grafik yang informatif dan menarik.
from sklearn.model\_selection import train\_test\_split #Untuk membagi data menjadi bagian pelatihan dan pengujian model.
from sklearn.preprocessing import StandardScaler, label\_binarize #Untuk menstandarisasi fitur dengan mengubahnya menjadi distribusi dengan rata-rata 0 dan deviasi standa from sklearn.pipeline import Pipeline #Untuk menggabungkan beberapa langkah preprocessing dan pemodelan menjadi satu alur kerja, menyederhanakan proses.
from sklearn.model\_selection import GridSearchCV #Untuk mencari parameter terbaik untuk model machine learning secara otomatis, mengoptimalkan kinerja model.
from sklearn.metrics import classification\_report, confusion\_matrix, accuracy\_score, roc\_curve, auc #untuk mengevaluasi kinerja model, termasuk classification\_report, cofrom sklearn.linear\_model import LogisticRegression #Wengimplementasikan model regresi logistik, yang digunakan untuk klasifikasi biner.
from sklearn.tree import DecisionTreeClassifier #Untuk membuat model klasifikasi berbasis pohon keputusan, yang membagi data berdasarkan fitur untuk membuat keputusan.
from sklearn.neighbors import KNeighborsClassifier #Mengimplementasikan algoritma k-nearest neighbors (k-NN) untuk klasifikasi, yang mengklasifikasikan data berdasarkan from xgboost import XGBClassifier #Metode boosting yang efisien dan sering digunakan dalam kompetisi machine learning untuk klasifikasi dan regresi.
import numpy as np #Untuk operasi numerik dan penanganan array.
import xgboost as xgb #Metode boosting yang efisien dan sering digunakan dalam kompetisi machine learning untuk klasifikasi dan regresi.

#### Memuat data set

```
data = pd.read_csv('/content/winequality-red.csv', delimiter=';')
```

```
print(data.head())
```

#Menampilkan Beberapa Baris Pertama dari Dataset

```
fixed acidity volatile acidity citric acid residual sugar chlorides \
         7.4
                         0.70
                                     0.00
                                                              0.076
         7.8
                         0.88
                                     0.00
                                                     2.6
                                                              0.098
                                     0.04
                                                             0.092
         7.8
                         0.76
        11.2
                                                              0.075
                         0.28
                                     0.56
         7.4
                                                              0.076
                         0.70
                                     0.00
                                                     1.9
free sulfur dioxide total sulfur dioxide density
                                                  pH sulphates \
              11.0
                                  34.0 0.9978 3.51
                                                           0.56
                                                           0.68
              25.0
                                  67.0 0.9968 3.20
              15.0
                                                           0.65
                                  54.0 0.9970 3.26
              17.0
                                         0.9980 3.16
                                                           0.58
                                  60.0
             11.0
                                  34.0 0.9978 3.51
                                                           0.56
alcohol quality
   9.4
   9.8
   9.8
```

#### Memuat data set

```
duplicate_rows = data[data.duplicated()]
print(f"Jumlah baris duplikat: {len(duplicate_rows)}")
#Memeriksa duplikasi

Jumlah baris duplikat: 240
```

```
print("Cek Missing Values:")
print(data.isnull().sum())
#Mengidentifikasi nilai yang hilang dalam DataFrame data
Cek Missing Values:
fixed acidity
volatile acidity
citric acid
residual sugar
chlorides
free sulfur dioxide
total sulfur dioxide
density
pН
sulphates
alcohol
quality
dtype: int64
```

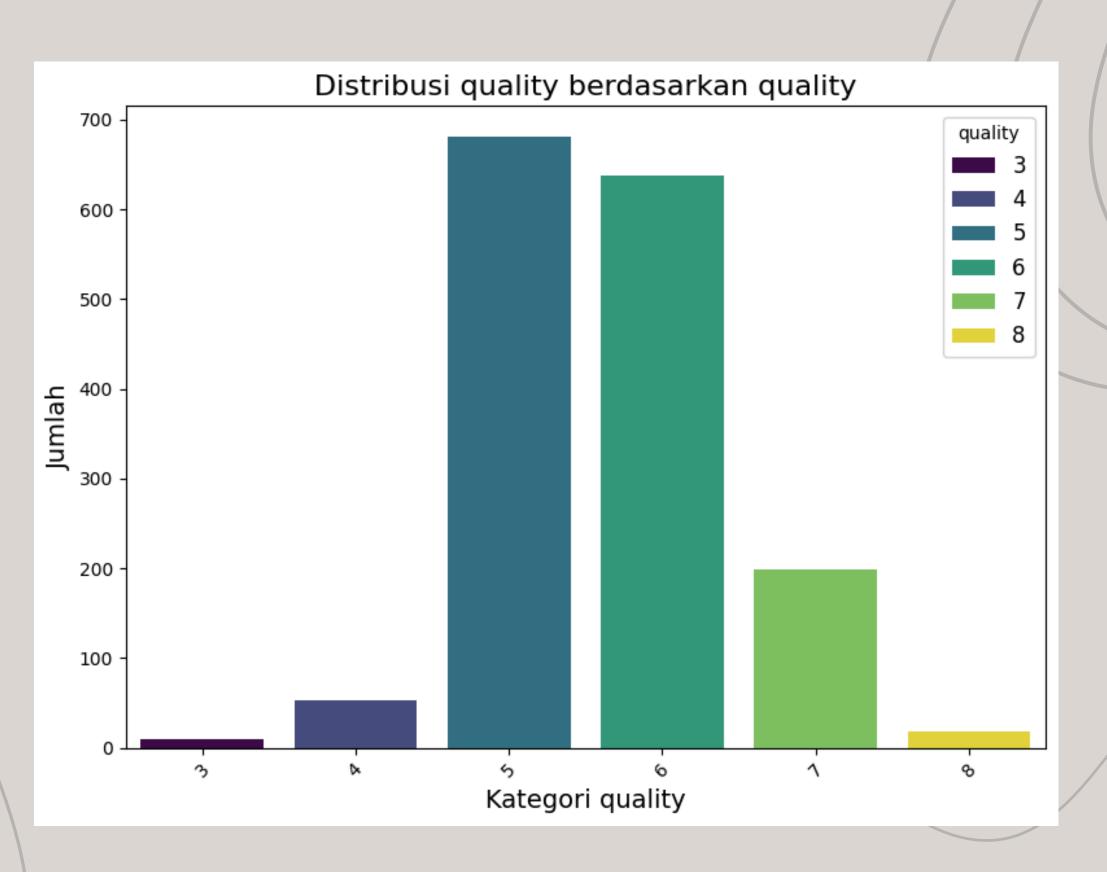
#### Pemrosesan Data

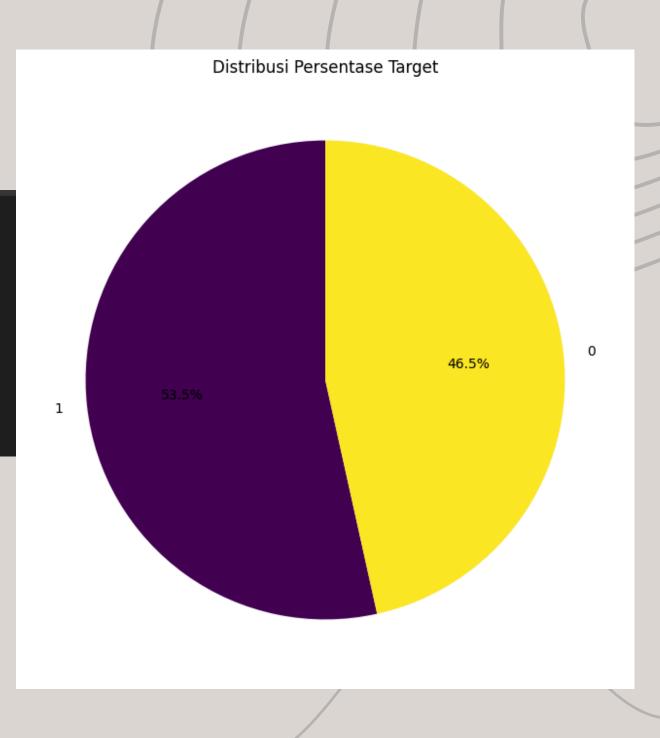
```
X = data.drop('quality', axis=1)
y = (data['quality'] >= 6).astype(int) # Binary classification: good quality if rating >= 6
#mempersiapkan data untuk analisis lebih lanjut
```

X\_train, X\_test, y\_train, y\_test = train\_test\_split(X, y, test\_size=0.2, random\_state=42)
##Membagi dataset menjadi data training dan data testing.

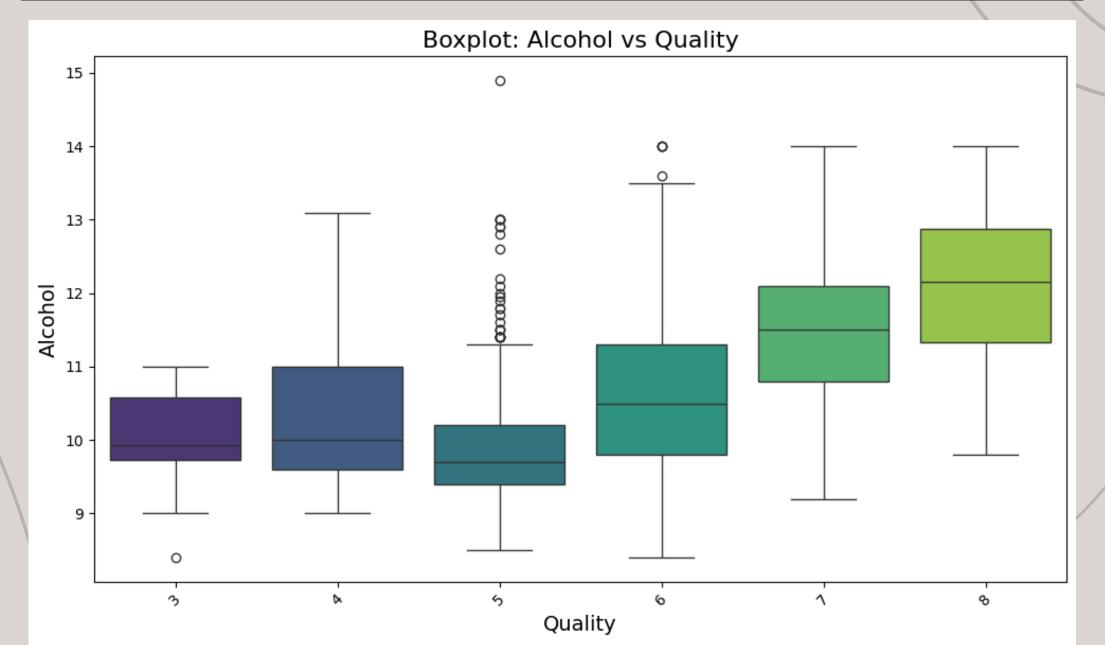
```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
#Melakukan standarisasi pada fitur-fitur dalam dataset
```

```
# Deteksi kolom kategorikal
target column = 'quality'
categorical_columns = data.select_dtypes(include=['object']).columns.tolist()
# Jika tidak ada kolom kategorikal, kita bisa menggunakan kolom 'quality' sebaga<mark>i kategorikal</mark>
if not categorical_columns:
    categorical_columns = [target_column]
# Hapus kolom target dari daftar kolom kategorikal (jika ada)
categorical_columns = [col for col in categorical_columns if col != target_column]
# Jika tidak ada kolom kategorikal lain, kita hanya akan menggunakan kolom target
if not categorical columns:
    categorical_columns = [target_column]
# Buat barplot untuk setiap kolom kategorikal terhadap target
for col in categorical_columns:
    plt.figure(figsize=(8, 6))
    sns.countplot(data=data, x=col, hue=target column, palette='viridis')
    plt.title(f'Distribusi {col} berdasarkan {target_column}', fontsize=16)
    plt.xlabel(f'Kategori {col}', fontsize=14)
    plt.ylabel('Jumlah', fontsize=14)
    plt.xticks(rotation=45)
    plt.legend(title=target column, loc='upper right', fontsize=12)
    plt.tight_layout()
    plt.show()
```



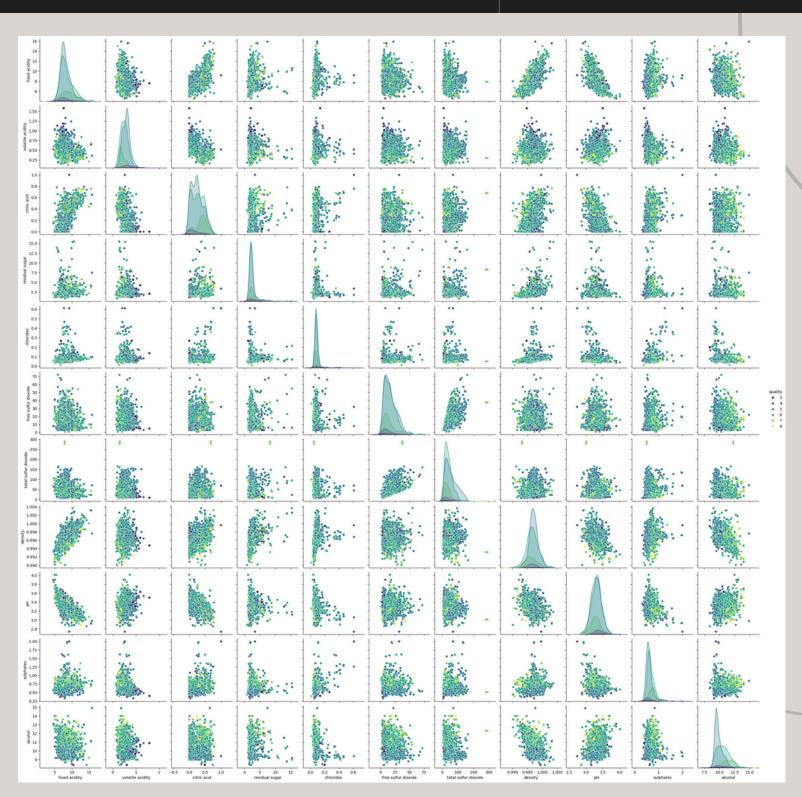


```
plt.figure(figsize=(10, 6))
sns.boxplot(x='quality', y='alcohol', data=data, palette='viridis')
plt.title('Boxplot: Alcohol vs Quality', fontsize=16)
plt.xlabel('Quality', fontsize=14)
plt.ylabel('Alcohol', fontsize=14)
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
#Membuat visualisasi boxplot yang menunjukkan hubungan antara kadar alkohol dan kualitas dalam dataset.
```



sns.pairplot(data, hue='quality', palette='viridis')
plt.show()

#Membuat visualisasi pairplot menggunakan Seaborn, yang menunjukkan hubungan antara semua pasangan variabel numerik dalam dataset

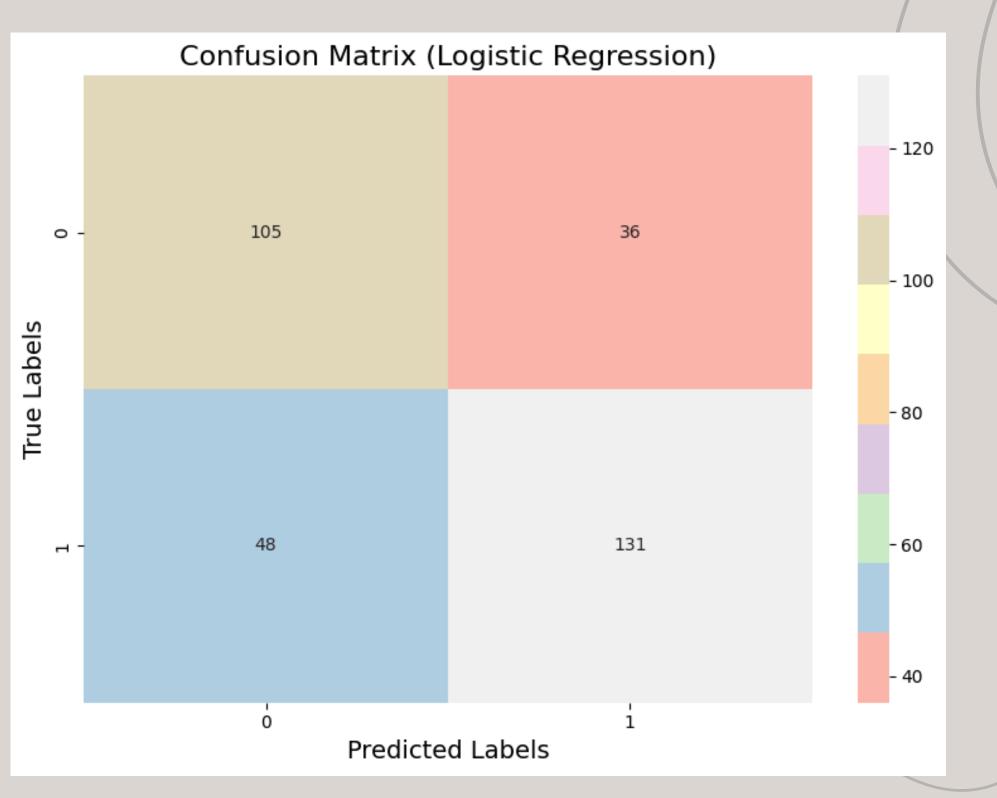


```
pipeline_lr = Pipeline([ ('scaler', StandardScaler()), ('logistic_regression', LogisticRegression(max_iter=1000)) ])
#Membuat pipeline menggunakan Logistic Regression
```

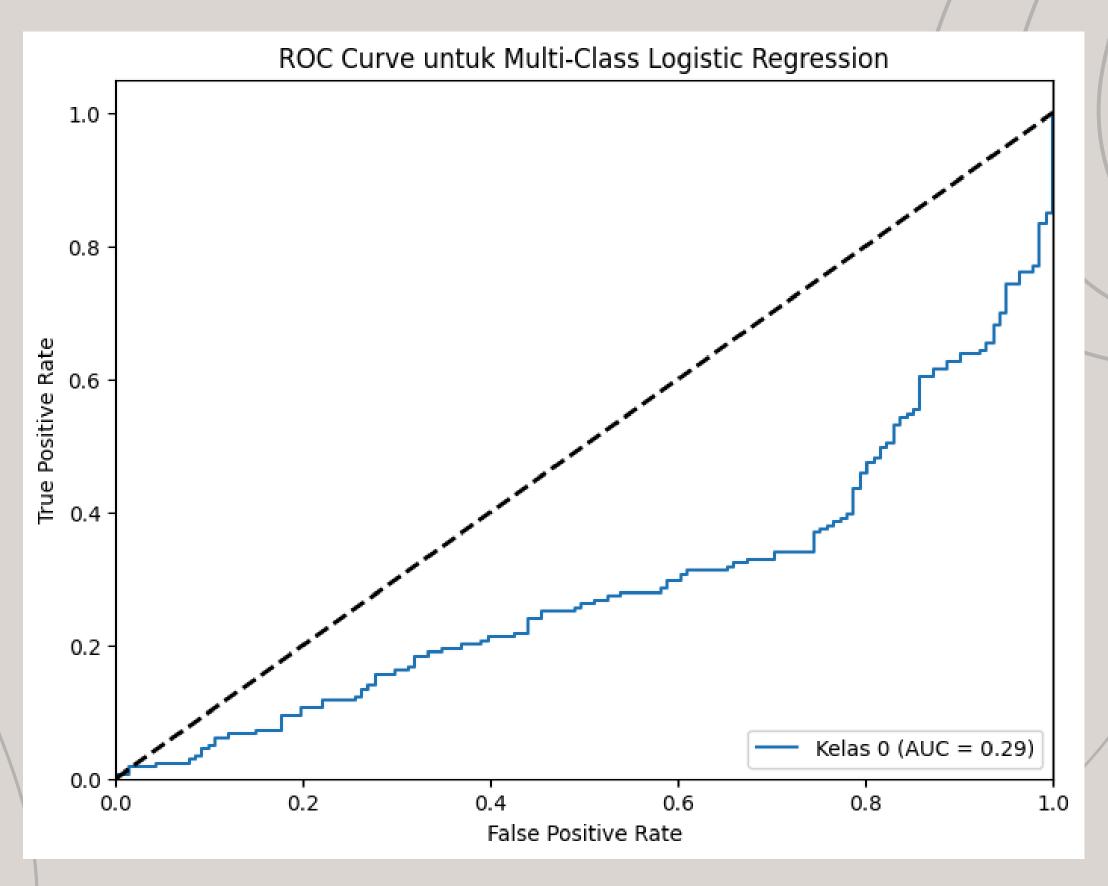
```
param_grid_lr = { 'logistic_regression__penalty': ['l1', 'l2'], 'logistic_regression__C': [0.01, 0.1, 1, 10, 100], 'logistic_regression__solver': ['liblinear'] }
grid_search_lr = GridSearchCV(pipeline_lr, param_grid_lr, cv=5, scoring='accuracy', verbose=1, n_jobs=-1)
grid_search_lr.fit(X_train, y_train)
#Melakukan hyperparameter tuning pada model regresi logistik menggunakan GridSearchCV
```

```
print("Best parameters (Logistic Regression):", grid_search_lr.best_params_)
print("Best score (Logistic Regression):", grid_search_lr.best_score_)
#Mengevaluasi dan melaporkan hasil dari proses hyperparameter tuning yang dilakukan dengan GridSearchCV.
Best parameters (Logistic Regression): {'logistic regression C': 1, 'logistic regression penalty': 'l1', 'logistic regression solver': 'liblinear'}
Best score (Logistic Regression): 0.7467310049019608
y pred lr = grid search lr.predict(X test)
print("Accuracy on test set (Logistic Regression):", accuracy score(y test, y pred lr))
print("\nClassification Report (Logistic Regression):")
print(classification_report(y_test, y_pred_lr))
#Mengevaluasi performa model regresi logistik yang telah dilatih dan dioptimalkan menggunakan GridSearchCV
Accuracy on test set (Logistic Regression): 0.7375
Classification Report (Logistic Regression):
              precision recall f1-score support
                   0.69
                            0.74
                                      0.71
                                                 141
                   0.78
                            0.73
                                      0.76
                                                 179
                                      0.74
                                                 320
    accuracy
                   0.74
                            0.74
                                      0.74
                                                 320
   macro avg
weighted avg
                  0.74
                            0.74
                                      0.74
                                                 320
```

```
cm_lr = confusion_matrix(y_test, y_pred_lr)
plt.figure(figsize=(8, 6))
sns.heatmap(cm_lr, annot=True, fmt='d', cmap='Pastel1')
plt.title('Confusion Matrix (Logistic Regression)', fontsize=16)
plt.xlabel('Predicted Labels', fontsize=14)
plt.ylabel('True Labels', fontsize=14)
plt.tight_layout()
plt.show()
#Membuat dan menampilkan confusion matrix dari model regresi logistik yang telah dilatih.
```



```
# Binarize target untuk multiclass
y_true = label_binarize(y_test, classes=np.unique(y))
best_model = grid_search_lr.best_estimator_ # Assign the best model from grid search
y_score = best_model.predict_proba(X_test) # Probabilitas prediksi untuk semua kelas
# Binarize y test untuk multi-class ROC
y_binarized = label_binarize(y_test, classes=np.unique(y))
n classes = y binarized.shape[1]
# Menghitung ROC Curve dan AUC untuk setiap kelas
fpr = \{\}
tpr = {}
roc_auc = {}
# Menggunakan predict_proba untuk mendapatkan probabilitas dari regresi logistik
# Use best model instead of log reg
y_score = best_model.predict_proba(X_test_scaled) # Probabilitas prediksi untuk semua kelas
for i in range(n_classes):
    fpr[i], tpr[i], _ = roc_curve(y_binarized[:, i], y_score[:, i])
    roc_auc[i] = auc(fpr[i], tpr[i])
# Plot ROC Curve untuk setiap kelas
plt.figure(figsize=(8, 6))
for i in range(n classes):
    plt.plot(fpr[i], tpr[i], label=f'Kelas {i} (AUC = {roc_auc[i]:.2f})')
plt.plot([0, 1], [0, 1], 'k--', lw=2)
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve untuk Multi-Class Logistic Regression')
plt.legend(loc='lower right')
plt.show()
```



```
pipeline_dt = Pipeline([ ('decision_tree', DecisionTreeClassifier()) ])
#Membuat pipeline menggunakan Decision Tree Classifier
```

```
param_grid_dt = { 'decision_tree__criterion': ['gini', 'entropy'], 'decision_tree__max_depth': [None, 5, 10, 20], 'decision_tree__min_samples_split': [2, 5, 10], 'decision_tree__min_samples_leaf': [1, 2, 4] grid_search_dt = GridSearchCV(pipeline_dt, param_grid_dt, cv=5, scoring='accuracy', verbose=1, n_jobs=-1) grid_search_dt.fit(X_train, y_train) #Melakukan hyperparameter tuning pada model decision tree menggunakan GridSearchCV
```

```
Fitting 5 folds for each of 72 candidates, totalling 360 fits

GridSearchCV

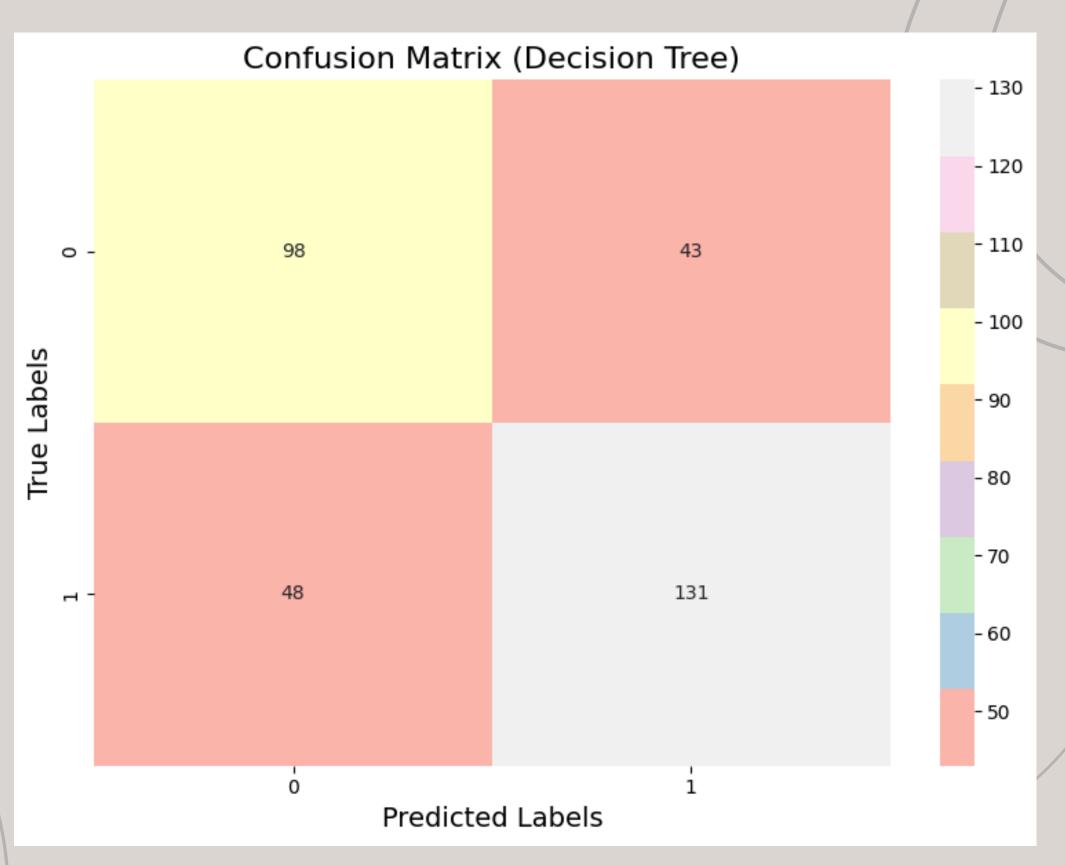
DecisionTreeClassifier

DecisionTreeClassifier
```

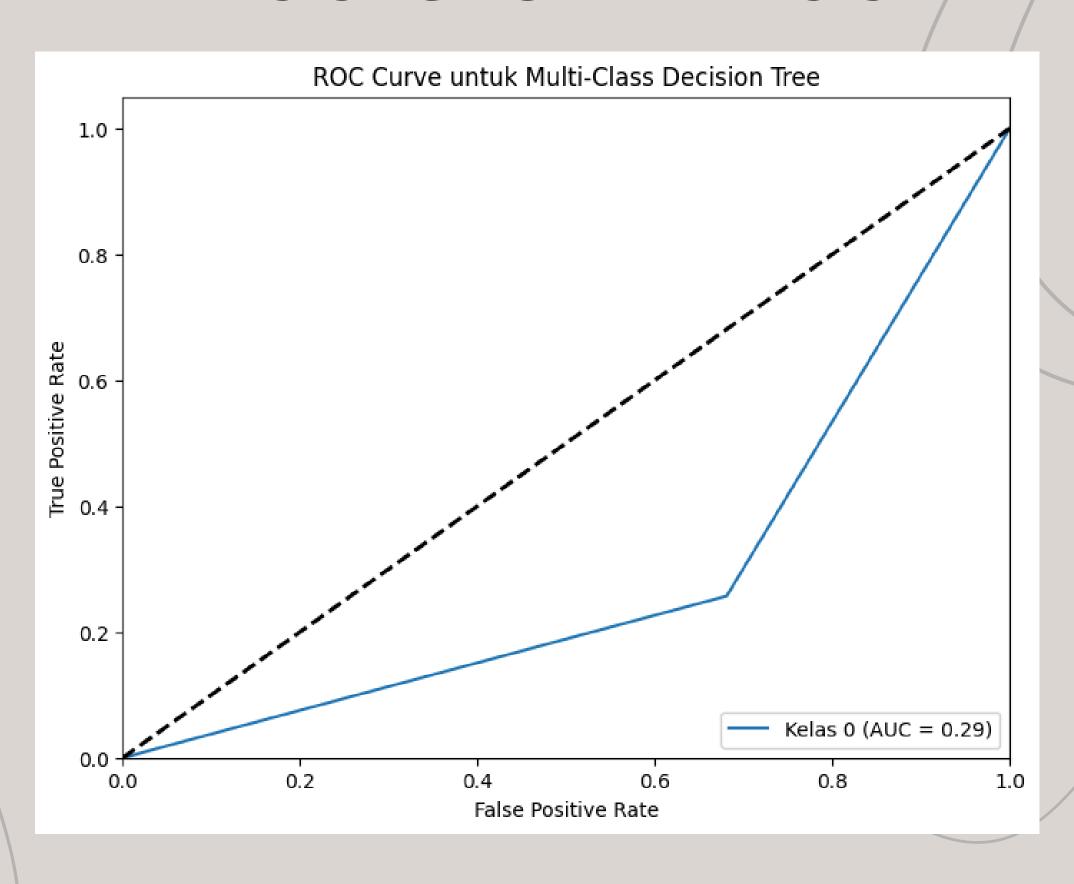
```
print("Best parameters (Decision Tree):", grid_search_dt.best_params_)
print("Best score (Decision Tree):", grid_search_dt.best_score_)
#Mengevaluasi performa model decision tree yang telah dilatih dan dioptimalkan menggunakan GridSearchCV
Best parameters (Decision Tree): {'decision_tree__criterion': 'gini', 'decision_tree__max_depth': 20, 'decision_tree__min_samples_leaf': 1, 'decision_tree__min_samples_split': 2}
Best score (Decision Tree): 0.7443412990196079
y_pred_dt = grid_search_dt.predict(X_test)
print("Accuracy on test set (Decision Tree):", accuracy_score(y_test, y_pred_dt))
print("\nClassification Report (Decision Tree):")
print(classification_report(y_test, y_pred_dt))
 #Mengevaluasi dan melaporkan hasil dari proses hyperparameter tuning yang dilakukan dengan GridSearchCV.
Accuracy on test set (Decision Tree): 0.715625
Classification Report (Decision Tree):
              precision recall f1-score support
                   0.67
                             0.70
                                       0.68
                                                 141
                   0.75
                             0.73
                                       0.74
                                                 179
                                       0.72
                                                 320
    accuracy
                                       0.71
                                                 320
                   0.71
                             0.71
   macro avg
                   0.72
                             0.72
                                       0.72
                                                 320
 weighted avg
```

```
cm_dt = confusion_matrix(y_test, y_pred_dt)
plt.figure(figsize=(8, 6))
sns.heatmap(cm_dt, annot=True, fmt='d', cmap='Pastel1')
plt.title('Confusion Matrix (Decision Tree)', fontsize=16)
plt.xlabel('Predicted Labels', fontsize=14)
plt.ylabel('True Labels', fontsize=14)
plt.tight_layout()
plt.show()
#Membuat dan menampilkan confusion matrix dari model decision tree yang telah dilatih.
```

# Decision Tree Confusion Matrix (Decision Tree)



```
# Binarize target untuk multiclass
y_true = label_binarize(y_test, classes=np.unique(y))
best_model = grid_search_lr.best_estimator_ # Assign the best model from grid search
y_score = best_model.predict_proba(X_test) # Probabilitas prediksi untuk semua kelas
# Binarize y_test untuk multi-class ROC
y_binarized = label_binarize(y_test, classes=np.unique(y))
n_classes = y_binarized.shape[1]
# Menghitung ROC Curve dan AUC untuk setiap kelas
fpr = {}
tpr = {}
roc_auc = {}
# Menggunakan predict_proba untuk mendapatkan probabilitas dari Decision Tree
dt classifier = DecisionTreeClassifier() # You can pass hyperparameters here if needed
dt_classifier.fit(X_train_scaled, y_train) # Assuming you have X_train_scaled and y_train
y_score = dt_classifier.predict_proba(X_test_scaled) # Probabilitas prediksi untuk semua kelas
for i in range(n_classes):
   fpr[i], tpr[i], _ = roc_curve(y_binarized[:, i], y_score[:, i])
   roc_auc[i] = auc(fpr[i], tpr[i])
# Plot ROC Curve untuk setiap kelas
plt.figure(figsize=(8, 6))
for i in range(n classes):
    plt.plot(fpr[i], tpr[i], label=f'Kelas {i} (AUC = {roc_auc[i]:.2f})')
plt.plot([0, 1], [0, 1], 'k--', lw=2)
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve untuk Multi-Class Decision Tree')
plt.legend(loc='lower right')
plt.show()
```



```
print("Best parameters (k-NN):", grid search knn.best params )
print("Best score (k-NN):", grid_search_knn.best_score_)
#Mengevaluasi performa model k-NN yang telah dilatih dan dioptimalkan menggunakan GridSearchCV
Best parameters (k-NN): {'knn_metric': 'euclidean', 'knn_n_neighbors': 11, 'knn_weights': 'distance'}
Best score (k-NN): 0.7959589460784313
y pred knn = grid search knn.predict(X test)
print("Accuracy on test set (k-NN):", accuracy_score(y_test, y_pred_knn))
print("\nClassification Report (k-NN):")
print(classification_report(y_test, y_pred_knn))
#Mengevaluasi dan melaporkan hasil dari proses hyperparameter tuning yang dilakukan dengan GridSearchCV.
Accuracy on test set (k-NN): 0.790625
Classification Report (k-NN):
                          recall f1-score support
             precision
                   0.77
                            0.74
                                       0.76
                                                 141
                   0.80
                            0.83
                                      0.82
                                                 179
                                       0.79
                                                 320
    accuracy
   macro avg
                   0.79
                             0.79
                                       0.79
                                                 320
                  0.79
weighted avg
                             0.79
                                       0.79
                                                 320
```

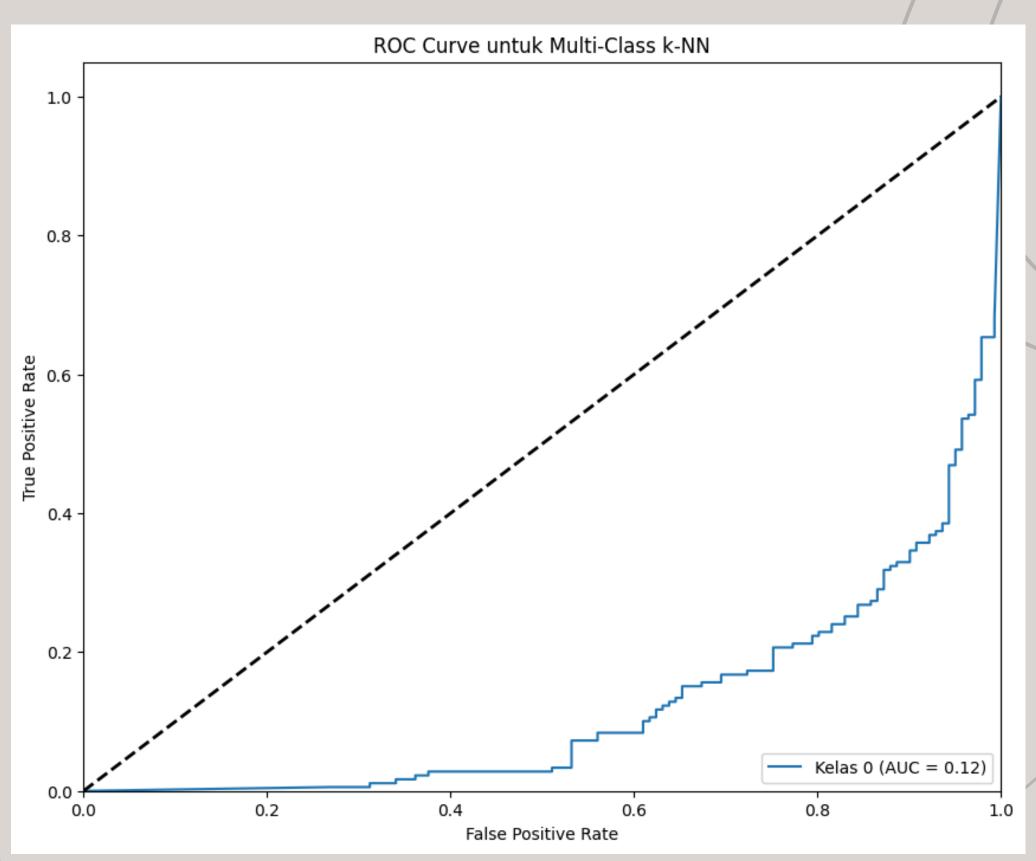
```
cm_knn = confusion_matrix(y_test, y_pred_knn)
plt.figure(figsize=(8, 6))
sns.heatmap(cm_knn, annot=True, fmt='d', cmap='Pastel1')
plt.title('Confusion Matrix (k-NN)', fontsize=16)
plt.xlabel('Predicted Labels', fontsize=14)
plt.ylabel('True Labels', fontsize=14)
plt.tight_layout()
plt.show()
#Membuat dan menampilkan confusion matrix dari model k-NN yang telah dilatih.
```

#### K-Nearest Neighbors Confusion Matrix (k-NN) - 140 - 120 105 **True Labels** - 100 - 80 31 148 - 60 - 40 **Predicted Labels**

```
# Binarize
y_true = 1  # Prediksi menggunakan model terbaik
           y pred = best model knn.predict(X test)
y_score =
            # Menggunakan predict_proba untuk mendapatkan probabilitas dari k-NN
           y_score = best_model_knn.predict_proba(X_test)
# Binarize
# Change:
            # Menghitung ROC Curve dan AUC untuk setiap kelas
y binarize
            fpr = {}
n classes
            tpr = {}
            roc_auc = {}
# Split th
X train, X
            for i in range(n classes):
                fpr[i], tpr[i], _ = roc_curve(y_binarized[:, i], y_score[:, i])
# Standard
                roc_auc[i] = auc(fpr[i], tpr[i])
scaler = S
X_train_sc
X_test_sca # Plot ROC Curve untuk setiap kelas
            plt.figure(figsize=(10, 8))
# K-Neares
           for i in range(n_classes):
pipeline_k
                plt.plot(fpr[i], tpr[i], label=f'Kelas {i} (AUC = {roc_auc[i]:.2f})')
    ('scal
    ('knn'
            plt.plot([0, 1], [0, 1], 'k--', lw=2)
            plt.xlim([0.0, 1.0])
            plt.ylim([0.0, 1.05])
param_grid
            plt.xlabel('False Positive Rate')
            plt.ylabel('True Positive Rate')
            plt.title('ROC Curve untuk Multi-Class k-NN')
            plt.legend(loc='lower right')
            plt.show()
grid_search_knn = GridSearchCV(pipeline_knn, param_grid_knn, cv=5, scoring='accuracy', verbose=1, n_jobs=-1)
grid_search_knn.fit(X_train, y_train)
# Model terbaik
best_model_knn = grid_search_knn.best_estimator_
```

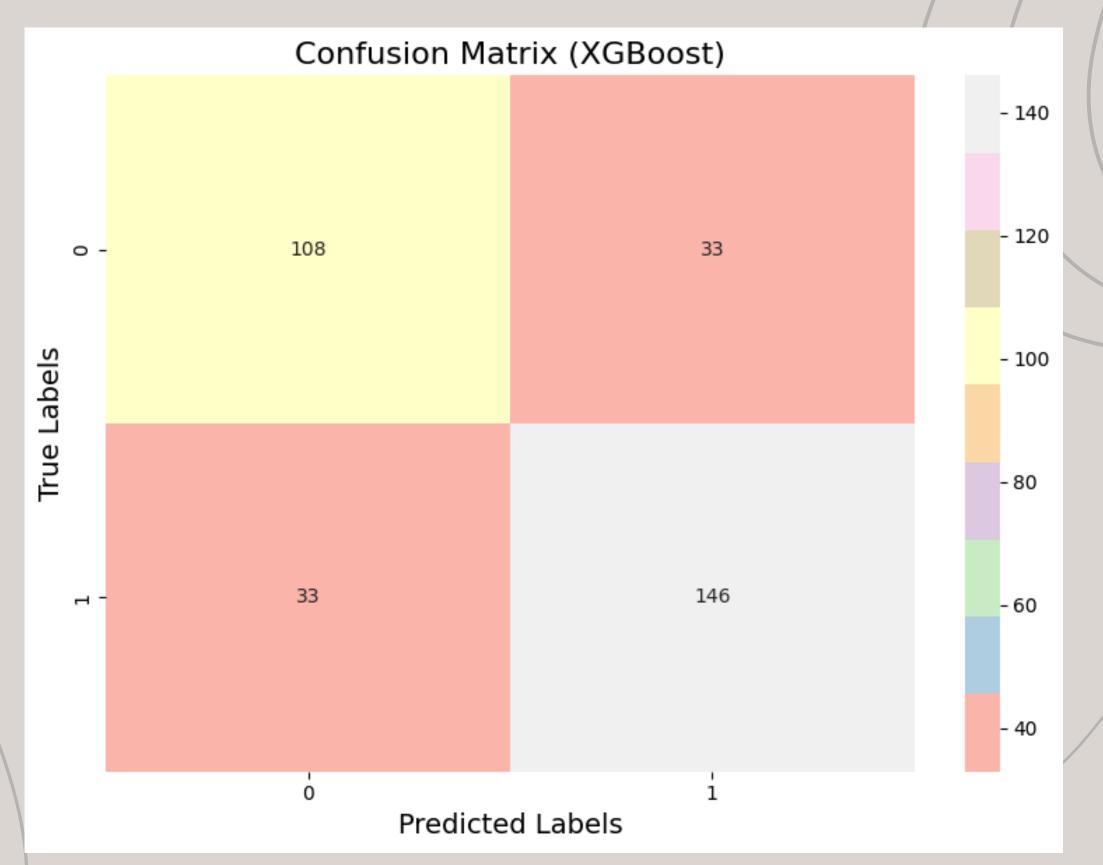
```
# Prediksi menggunakan model terbaik
y_pred = best_model_knn.predict(X_test)
# Menggunakan predict_proba untuk mendapatkan probabilitas dari k-NN
y score = best model knn.predict proba(X test)
# Menghitung ROC Curve dan AUC untuk setiap kelas
fpr = \{\}
tpr = {}
roc_auc = {}
for i in range(n_classes):
    fpr[i], tpr[i], _ = roc_curve(y_binarized[:, i], y_score[:, i])
   roc_auc[i] = auc(fpr[i], tpr[i])
# Plot ROC Curve untuk setiap kelas
plt.figure(figsize=(10, 8))
for i in range(n_classes):
    plt.plot(fpr[i], tpr[i], label=f'Kelas {i} (AUC = {roc_auc[i]:.2f})')
plt.plot([0, 1], [0, 1], 'k--', lw=2)
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve untuk Multi-Class k-NN')
plt.legend(loc='lower right')
plt.show()
```

# K-Nearest Neighbors ROC Curve untuk Multi-Class k-NN



```
print("Best parameters (XGBoost):", grid_search_xgb.best_params_)
print("Best score (XGBoost):", grid_search_xgb.best_score_)
#Mengevaluasi performa model XGBoost yang telah dilatih dan dioptimalkan menggunakan GridSearchCV
Best parameters (XGBoost): {'xgb_colsample_bytree': 0.8, 'xgb_gamma': 0, 'xgb_learning_rate': 0.2, 'xgb_max_depth': 5, 'xgb_n_estimators': 100, 'xgb_reg_alpha': 0.1, 'xgb_reg_lambda': 1, 'xgb_subsam
Best score (XGBoost): 0.8053615196078432
y_pred_xgb = grid_search_xgb.predict(X_test)
print("Accuracy on test set (XGBoost):", accuracy_score(y_test, y_pred_xgb))
print("\nClassification Report (XGBoost):")
print(classification_report(y_test, y_pred_xgb))
#Mengevaluasi dan melaporkan hasil dari proses hyperparameter tuning yang dilakukan dengan GridSearchCV.
Accuracy on test set (XGBoost): 0.79375
Classification Report (XGBoost):
              precision recall f1-score support
                                                 141
                                      0.77
                                      0.82
                                                179
                                                320
    accuracy
                                     0.79
                                                320
   macro avg
 weighted avg
```

```
cm_xgb = confusion_matrix(y_test, y_pred_xgb)
plt.figure(figsize=(8, 6))
sns.heatmap(cm_xgb, annot=True, fmt='d', cmap='Pastel1')
plt.title('Confusion Matrix (XGBoost)', fontsize=16)
plt.xlabel('Predicted Labels', fontsize=14)
plt.ylabel('True Labels', fontsize=14)
plt.tight_layout()
plt.show()
#Membuat dan menampilkan confusion matrix dari model XGBoost yang telah dilatih.
```



```
# Binarize target untuk multiclass
y_true = label_binarize(y_test, classes=np.unique(y))
best_model = grid_search_lr.best_estimator_ # Assign the best model from grid search
y_score = best_model.predict_proba(X_test) # Probabilitas prediksi untuk semua kelas
# Binarize y test untuk multi-class ROC
y binarized = label binarize(y test, classes=np.unique(y))
n_classes = y_binarized.shape[1]
# Menghitung ROC Curve dan AUC untuk setiap kelas
fpr = {}
tpr = {}
roc_auc = {}
# Menggunakan predict_proba untuk mendapatkan probabilitas dari XGBoost
xgb classifier = xgb.XGBClassifier() # Create an XGBoost classifier object
xgb_classifier.fit(X_train_scaled, y_train) # Assuming you have X_train_scaled and y_train for training
y score = xgb classifier.predict proba(X test scaled) # Probabilitas prediksi untuk semua kelas
for i in range(n_classes):
    fpr[i], tpr[i], _ = roc_curve(y_binarized[:, i], y_score[:, i])
   roc_auc[i] = auc(fpr[i], tpr[i])
# Plot ROC Curve untuk setiap kelas
plt.figure(figsize=(8, 6))
for i in range(n_classes):
   plt.plot(fpr[i], tpr[i], label=f'Kelas {i} (AUC = {roc_auc[i]:.2f})')
plt.plot([0, 1], [0, 1], 'k--', lw=2)
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve untuk Multi-Class XGBoost')
plt.legend(loc='lower right')
plt.show()
```

