Presentasi UTS Machine Learning

Regression Model

Presented by Anita Firda N (1103213117)

Import library

Berbagai macam library yang digunakan

```
import pandas as pd # Untuk membaca dan menulis data dari berbagai format file import numpy as np #Untuk operasi numerik dan penanganan array. import matplotlib.pyplot as plt #Untuk membuat plot dan visualisasi. import seaborn as sns #Untuk visualisasi data statistik, membuat grafik yang informatif dan menarik. from sklearn.model_selection import train_test_split #Untuk membagi data menjadi bagian pelatihan dan pengujian model. from sklearn.model_selection import GridSearchCV #Untuk mencari parameter terbaik untuk model machine learning secara otomatis, mengoptimalkan kinerja model. from sklearn.preprocessing import PolynomialFeatures, StandardScaler #Untuk membuat fitur polinomial dan melakukan penskalaan data, meningkatkan akurasi model. from sklearn.pipeline import Pipeline #Untuk menggabungkan beberapa langkah preprocessing dan pemodelan menjadi satu alur kerja, menyederhanakan proses. from sklearn.tree import DecisionTreeRegressor #Untuk membuat model Decision Tree Regression, digunakan untuk memprediksi nilai numerik. from sklearn.neighbors import KNeighborsRegressor #Untuk membuat model K-Nearest Neighbors Regression, digunakan untuk memprediksi nilai numerik berdasarkan tetangga terdekat. from sklearn.linear_model import LinearRegression #Untuk membuat model Linear Regression, digunakan untuk memprediksi nilai numerik dengan hubungan linear. from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score #Untuk mengevaluasi kinerja model regression, mengukur akurasi prediksi.
```

Memuat data set

Menggunakan drive

```
from google.colab import drive
drive.mount('/content/drive')
# Mount Google Drive

file_path = '/content/drive/MyDrive/RegresiUTSTelkomNew.csv'
#Read CSV file into DataFrame, handling errors and specifying encoding
df = pd.read_csv(file_path, on_bad_lines='skip', encoding='latin-1')
# Read CSV file into DataFrame

df.head()
#Menampilkan beberapa baris pertama DataFrame
```

	Dri	ve already	y mounted	at /conter	nt/drive; †	to attempt	to forcibly	remount,	call drive	.mount("/c	ontent/o	drive", force_remount=True).	
		x2	x4	х7	х8	x41	x48	x64	x68	x70	x1		
	0	48.73215	70.32679	-24.83777	8.76630	202.18689	-125.94783	12.59163	-88.37882	46.49209	2001.0		
	1	50.95714	55.81851	-18.54940	-3.27872	13.09302	133.08169	1.75729	-12.14279	2.07554	2001.0		
	2	48.24750	36.29772	-26.21683	5.05097	-0.01744	778.02248	-11.63176	-83.15795	-22.11505	2001.0		
	3	50.97020	67.09964	-16.81409	-12.48207	28.68782	150.29661	-4.05003	-47.75605	-97.42948	2001.0		
	4	50.54767	92.35066	-19.04928	20.67345	51.41086	-31.97030	0.51657	-9.41185	33.54907	2001.0		
ш													

Analisis Data Eksploratif (EDA)

```
min
                                                       39.960375
                                                                    44.17598
                                           4.41850
dtype: int64)
```

memahami karakteristik data secara keseluruhan sebelum melakukan pemodelan

```
eda_report = df.describe().transpose()
#Untuk melakukan analisis data eksploratif (EDA) dasar pada DataFrame df dan menyimpan hasilnya dalam variabel eda_report.

missing_values = df.isnull().sum()
#Untuk mencari nilai nilai data yang hilang

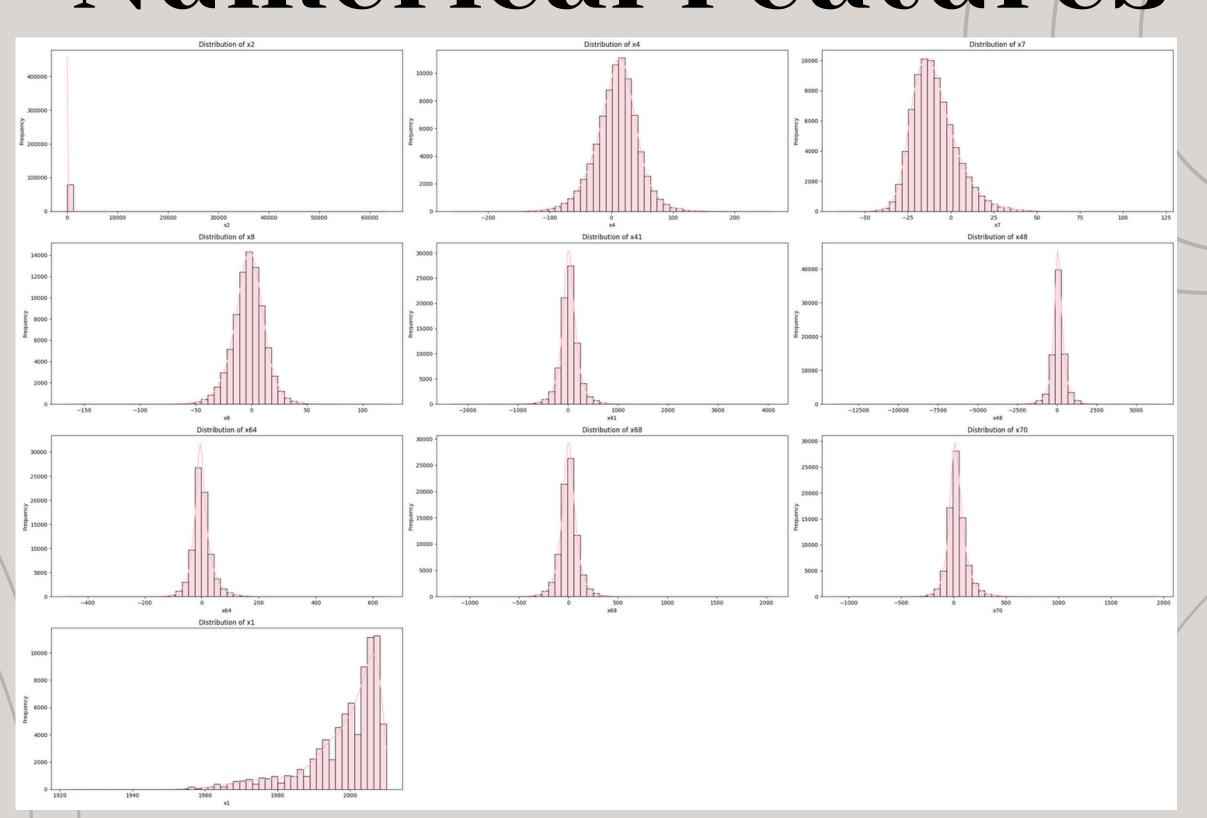
eda_report, missing_values
#Menampilkan statistik EDA dan nilai yang hilang
```

Visualisasi Distribusi Numerical Features

```
numerical_cols = df.columns

plt.figure(figsize=(30, 20))
for idx, col in enumerate(numerical_cols, 1):
    plt.subplot(4, 3, idx)
    sns.histplot(df[col], kde=True, bins=50, color='pink')
    plt.title(f'Distribution of {col}')
    plt.xlabel(col)
    plt.ylabel('Frequency')
plt.tight_layout()
plt.show()
```

Visualisasi Distribusi Numerical Features

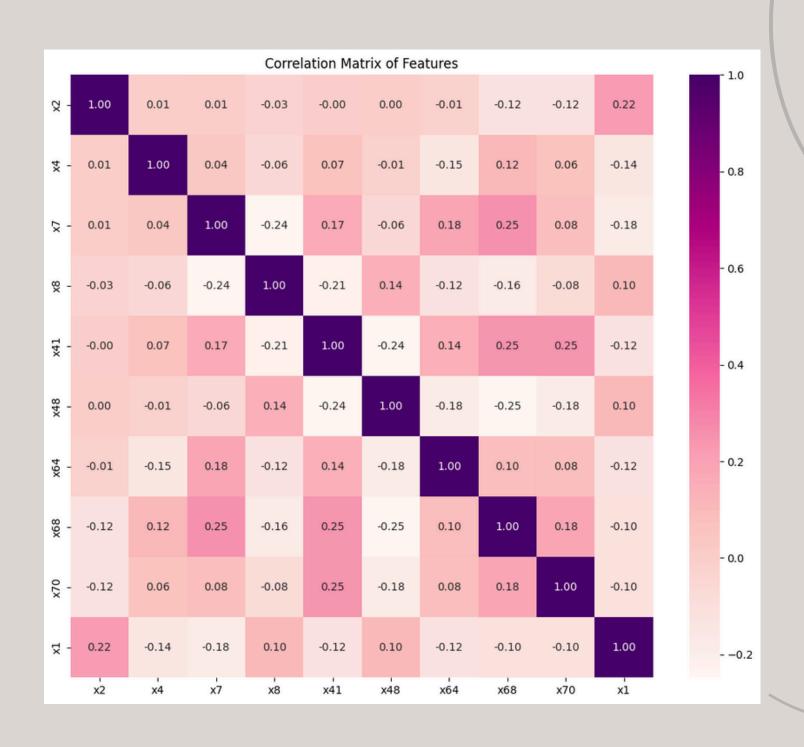


Visualisasi Correlation Matrix

```
correlation_matrix = df.corr()

plt.figure(figsize=(12, 10))
sns.heatmap(correlation_matrix, annot=True, cmap='RdPu', fmt=".2f")
plt.title("Correlation Matrix of Features")
plt.show()
```

Visualisasi Correlation Matrix



Model Evaluation Result

```
imputer = SimpleImputer(strategy='mean')
df_imputed = pd.DataFrame(imputer.fit_transform(df), columns=df.columns)
#Untuk menangani missing values (nilai yang hilang) dalam dataset.
X = df_imputed.drop(columns=['x1'])
y = df imputed['x1']
#Membagi dataset menjadi fitur (X) dan target (y)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random state=42)
#Membagi dataset menjadi data training dan data testing.
pipelines = {
    "Polynomial Regression": Pipeline([
        ('poly', PolynomialFeatures()), #Membuat fitur polinomial dan interaksi untuk meningkatkan fleksibilitas model linear regression. Generates polynomial and interaction features
        ('scaler', StandardScaler()), #Melakukan standardisasi fitur (mensentriskan data dengan mengurangi mean dan membaginya dengan standar deviasi) agar model lebih robust.
        ('model', LinearRegression()) #Model regresi linear.
    "Decision Tree": Pipeline([
        ('model', DecisionTreeRegressor(random_state=42)) #Model decision tree untuk regresi.
    ]),
    "k-NN": Pipeline([
        ('scaler', StandardScaler()), #Melakukan standardisasi fitur.
        ('model', KNeighborsRegressor()) #Model k-Nearest Neighbors untuk regresi.
    1)
#Menggabungkan beberapa langkah preprocessing dan pemodelan menjadi satu alur kerja.
param grids = {
    "Polynomial Regression": {'poly_degree': [1, 2, 3]}, #Mencoba nilai 1, 2, dan 3 untuk derajat polinomia
    "Decision Tree": {'model_max_depth': [5, 10, 20], #Mencoba nilai 5, 10, dan 20 untuk kedalaman maksimum decision tree.
                       'model__min_samples_split': [2, 5, 10]}, #Mencoba nilai 2, 5, dan 10 untuk jumlah minimum sampel yang dibutuhkan untuk membagi node.
    "k-NN": {'model__n_neighbors': [3, 5, 10]} #Mencoba nilai 3, 5, dan 10 untuk jumlah tetangga terdekat.
#Mendefinisikan grid parameter yang akan dicoba untuk setiap model machine learning selama proses hyperparameter tuning.
```

Model Evaluation Result

```
evaluation_results = []
for model_name, pipeline in pipelines.items():
        #elakukan grid search untuk menemukan kombinasi parameter terbaik dari param grids untuk model tersebut.
        grid search = GridSearchCV(pipeline, param grids[model name], cv=3, scoring='neg mean squared error', n jobs=-1)
        grid_search.fit(X_train, y_train)
        #Mengambil model terbaik yang ditemukan oleh grid search.
        best model = grid search.best estimator
        #Melakukan prediksi pada data testing menggunakan model terbaik.
        y pred = best model.predict(X test)
        #Menghitung metrik evaluasi seperti MSE, MAE, dan R<sup>2</sup>.
        mse = mean_squared_error(y_test, y_pred)
        mae = mean absolute error(y test, y pred)
        r2 = r2_score(y_test, y_pred)
        #Menyimpan hasil evaluasi (nama model, parameter terbaik, dan metrik) dalam list evaluation_results.
        evaluation_results.append({
            "Model": model_name,
            "Best Parameters": grid search.best params,
            "MSE": mse,
            "MAE": mae,
            "R<sup>2</sup>": r<sup>2</sup>
    except ValueError as e:
        print(f"Error for {model name}: {e}")
#Melakukan grid search untuk setiap model yang didefinisikan dalam pipelines dan menyimpan hasil evaluasi dalam sebuah list.
evaluation_df = pd.DataFrame(evaluation_results)
print("Model Evaluation Results:")
print(evaluation df)
#Mengubah hasil evaluasi model yang tersimpan dalam list evaluation results menjadi DataFrame Pandas dan menampilkannya.
```

Model Evaluation Result

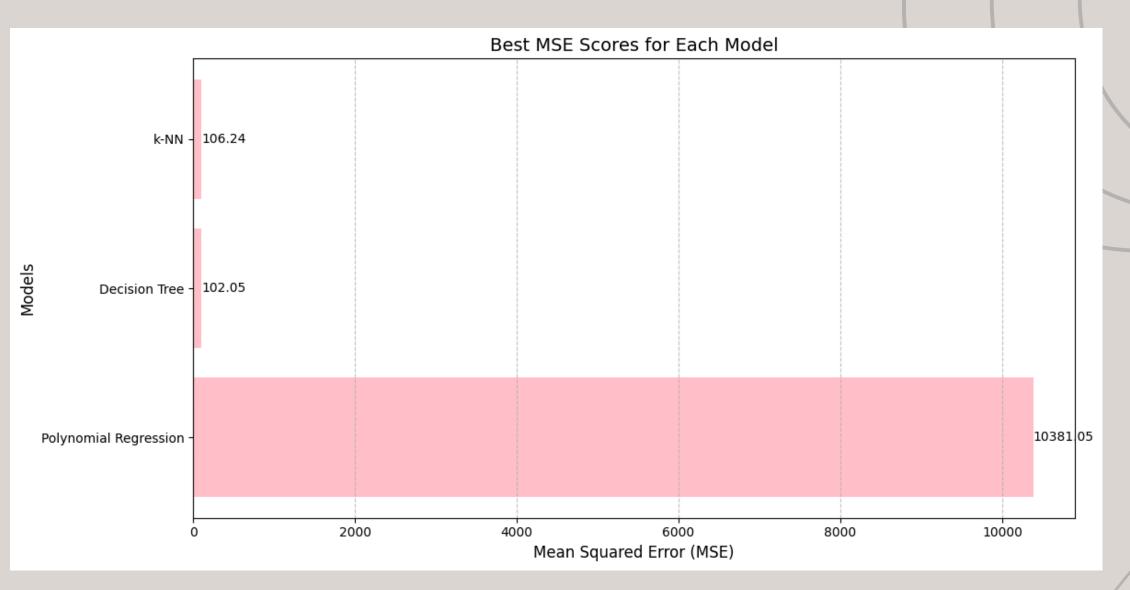
Best MSE Scores for Each Model

```
results = {}
for model_name, pipeline in pipelines.items():
    grid_search = GridSearchCV(pipeline, param_grids[model_name], cv=3, scoring='neg_mean_squared_error', n_jobs=-1)
    grid_search.fit(X train, y train)
    results[model name] = {
         'best_params': grid_search.best_params_,
        'best_score': -grid_search.best_score_
 #Melakukan grid search untuk setiap model yang didefinisikan dalam pipelines, mencari parameter terbaik, dan menyimpan parameter serta skor terbaik dalam dictionary results.
models = list(results.keys())
scores = [result['best score'] for result in results.values()]
best params = [str(result['best params']) for result in results.values()]
#Mempersiapkan data dari dictionary results agar mudah digunakan untuk visualisasi.
plt.figure(figsize=(12, 6))
plt.barh(models, scores, color='pink')
for i, v in enumerate(scores):
    plt.text(v + 0.1, i, f"{v:.2f}", va='center', fontsize=10)
plt.title('Best MSE Scores for Each Model', fontsize=14)
plt.xlabel('Mean Squared Error (MSE)', fontsize=12)
plt.ylabel('Models', fontsize=12)
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.tight layout()
plt.show()
#Membuat visualisasi bar chart horizontal untuk menampilkan skor MSE terbaik dari setiap model machine learning yang telah dievaluasi.
print("Best Parameters for Each Model:")
for model, params in zip(models, best_params):
    print(f"{model}: {params}")
#Menampilkan parameter terbaik (hyperparameter) yang ditemukan oleh grid search untuk setiap model.
```

Best MSE Scores for Each Model

```
results = {}
for model_name, pipeline in pipelines.items():
    grid_search = GridSearchCV(pipeline, param_grids[model_name], cv=3, scoring='neg_mean_squared_error', n_jobs=-1)
    grid_search.fit(X train, y train)
    results[model name] = {
         'best_params': grid_search.best_params_,
        'best_score': -grid_search.best_score_
 #Melakukan grid search untuk setiap model yang didefinisikan dalam pipelines, mencari parameter terbaik, dan menyimpan parameter serta skor terbaik dalam dictionary results.
models = list(results.keys())
scores = [result['best score'] for result in results.values()]
best params = [str(result['best params']) for result in results.values()]
#Mempersiapkan data dari dictionary results agar mudah digunakan untuk visualisasi.
plt.figure(figsize=(12, 6))
plt.barh(models, scores, color='pink')
for i, v in enumerate(scores):
    plt.text(v + 0.1, i, f"{v:.2f}", va='center', fontsize=10)
plt.title('Best MSE Scores for Each Model', fontsize=14)
plt.xlabel('Mean Squared Error (MSE)', fontsize=12)
plt.ylabel('Models', fontsize=12)
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.tight layout()
plt.show()
#Membuat visualisasi bar chart horizontal untuk menampilkan skor MSE terbaik dari setiap model machine learning yang telah dievaluasi.
print("Best Parameters for Each Model:")
for model, params in zip(models, best_params):
    print(f"{model}: {params}")
#Menampilkan parameter terbaik (hyperparameter) yang ditemukan oleh grid search untuk setiap model.
```

Best MSE Scores for Each Model

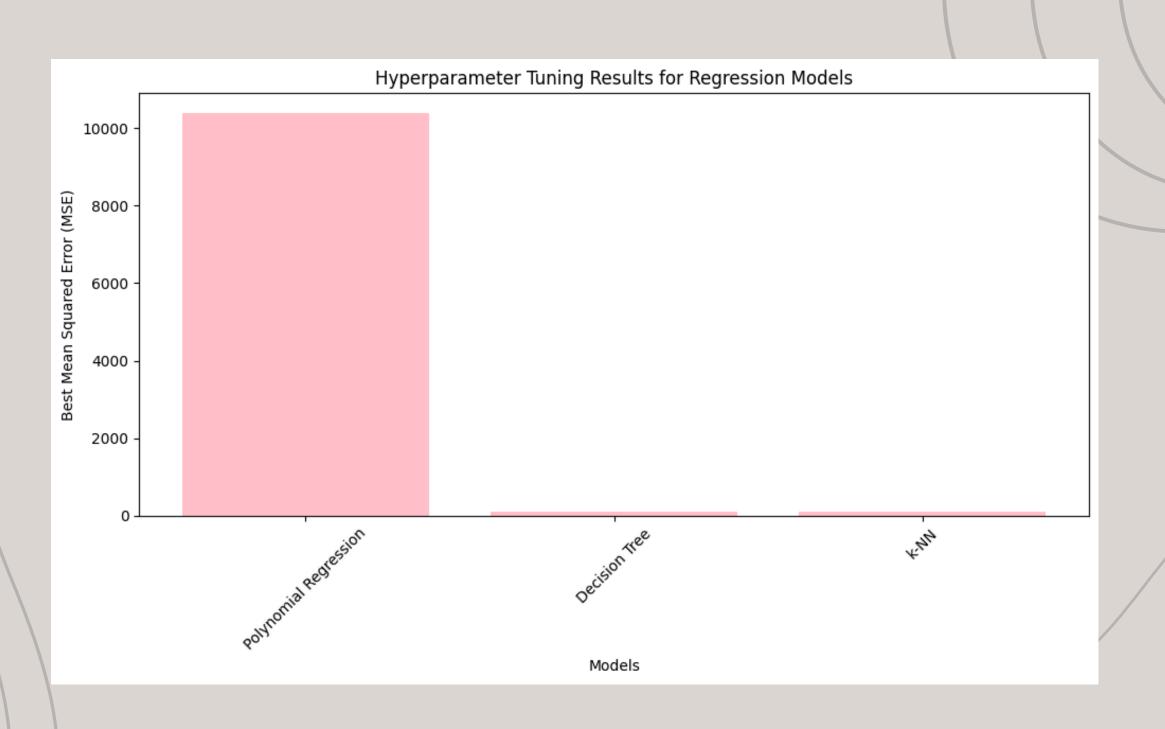


```
Best Parameters for Each Model:
Polynomial Regression: {'poly__degree': 1}
Decision Tree: {'model__max_depth': 5, 'model__min_samples_split': 2}
k-NN: {'model__n_neighbors': 10}
```

Hyperparameter Tuning Results for Regression Models

```
results = {}
for model_name, pipeline in pipelines.items():
    grid_search = GridSearchCV(pipeline, param_grids[model_name], cv=3, scoring='neg_mean_squared_error', n_jobs=-1)
    grid_search.fit(X_train, y_train)
    results[model name] = {
         'best params': grid search.best params,
         'best_score': -grid_search.best_score_
 #Melakukan grid search untuk setiap model yang didefinisikan dalam pipelines, mencari parameter terbaik (hyperparameter tuning), dan menyimpan parameter serta skor terbaik dalam dictionary re
results_df = pd.DataFrame(results).transpose()
#Mengubah dictionary results (yang berisi hasil grid search untuk setiap model) menjadi DataFrame Pandas dan melakukan transpose pada DataFrame tersebut.
plt.figure(figsize=(10, 6))
models = results_df.index
mse_values = results_df['best_score']
plt.bar(models, mse_values, color='pink')
plt.xlabel("Models")
plt.ylabel("Best Mean Squared Error (MSE)")
plt.title("Hyperparameter Tuning Results for Regression Models")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
 #Membuat visualisasi bar chart untuk menampilkan skor Mean Squared Error (MSE) terbaik dari setiap model machine learning setelah dilakukan hyperparameter tuning.
print("Hyperparameter Tuning Results:")
print(results df)
 #Menampilkan hasil secara detail
```

Hyperparameter Tuning Results for Regression Models



Hyperparameter Tuning Results for Regression Models

```
Hyperparameter Tuning Results:

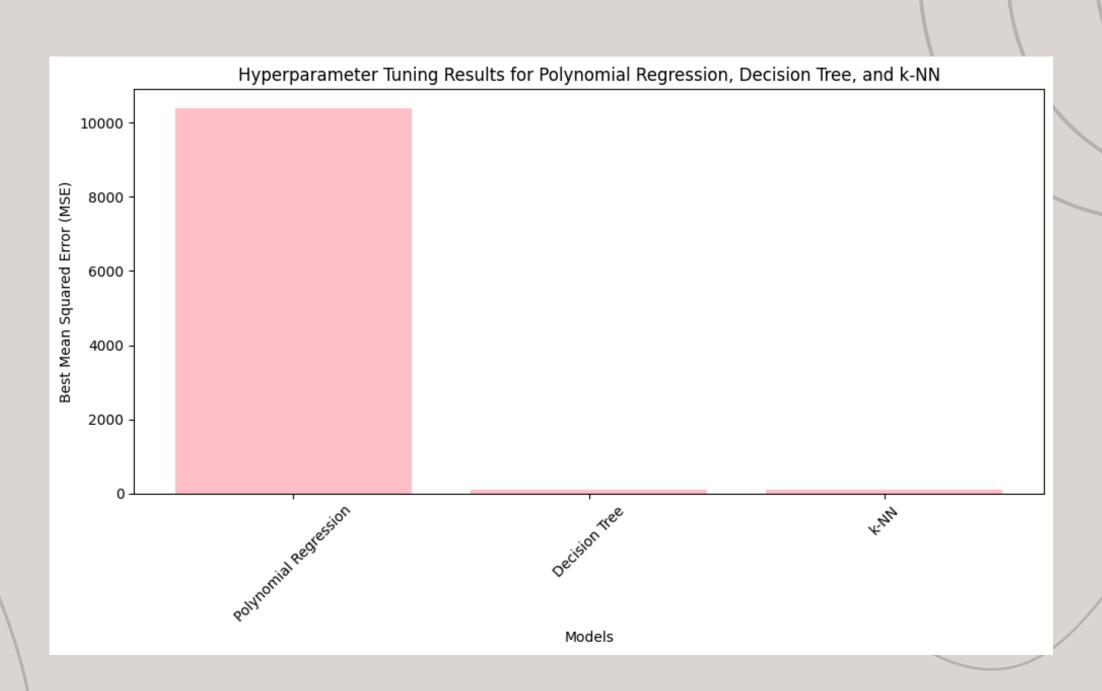
best_params \
Polynomial Regression {'poly_degree': 1}
Decision Tree {'model__max_depth': 5, 'model__min_samples_sp...
k-NN {'model__n_neighbors': 10}

best_score
Polynomial Regression 10381.047731
Decision Tree 102.04834
k-NN 106.238636
```

Hyperparameter Tuning Results for Polynomial Regression, Decision Tree, and k-NN

```
imputer = SimpleImputer(strategy='mean')
df_imputed = pd.DataFrame(imputer.fit_transform(df), columns=df.columns)
 #Untuk menangani missing values (nilai yang hilang) dalam dataset.
X = df_imputed.drop(columns=['x1'])
y = df_imputed['x1']
#Membagi dataset menjadi fitur (X) dan target (y)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
#Membagi dataset menjadi data training dan data testing.
results = {}
 or model name, pipeline in pipelines.items():
   grid_search = GridSearchCV(pipeline, param_grids[model_name], cv=3, scoring='neg_mean_squared_error', n_jobs=-1)
   grid_search.fit(X_train, y_train)
    results[model name] = {
        'best_params': grid_search.best_params_,
        'best_score': -grid_search.best_score_
 Melakukan grid search untuk setiap model yang didefinisikan dalam pipelines menggunakan data fitur dan target yang telah disesuaikan, mencari parameter terbaik (hyperparameter tuning), dan m
results_df = pd.DataFrame(results).transpose()
 Mengubah dictionary results (yang berisi hasil grid search untuk setiap model) menjadi DataFrame Pandas dan melakukan transpose pada DataFrame tersebut.
plt.figure(figsize=(10, 6))
models = results df.index
mse_values = results_df['best_score']
plt.bar(models, mse_values, color='pink')
plt.xlabel("Models")
plt.ylabel("Best Mean Squared Error (MSE)")
plt.title("Hyperparameter Tuning Results for Polynomial Regression, Decision Tree, and k-NN")
plt.xticks(rotation=45)
plt.tight_layout()
 Membuat visualisasi bar chart untuk menampilkan skor Mean Squared Error (MSE) terbaik dari setiap model (Polynomial Regression, Decision Tree, dan k-NN) setelah dilakukan hyperparameter tuni
print("Hyperparameter Tuning Results:")
print(results df)
  Menampilkan hasil secara detail
```

Hyperparameter Tuning Results for Polynomial Regression, Decision Tree, and k-NN



Hyperparameter Tuning Results for Polynomial Regression, Decision Tree, and k-NN

```
Hyperparameter Tuning Results:

best_params \
Polynomial Regression {'poly__degree': 1}

Decision Tree {'model__max_depth': 5, 'model__min_samples_sp...
k-NN {'model__n_neighbors': 10}

best_score

Polynomial Regression 10381.047731

Decision Tree 102.04834
k-NN 106.238636
```

Evaluasi setiap model dengan parameter terbaik

```
def evaluate_model(model, X_test, y_test, model_name="Model"):
    y_pred = model.predict(X_test)
    mse = mean squared error(y test, y pred)
    mae = mean_absolute_error(y_test, y_pred)
    r2 = r2_score(y_test, y_pred)
    print(f"{model name} Performance:")
    print(f"Mean Squared Error (MSE): {mse:.2f}")
    print(f"Mean Absolute Error (MAE): {mae:.2f}")
    print(f"R^2 Score: {r2:.2f}")
    print("\n")
    return mse, mae, r2
 Mendefinisikan sebuah fungsi bernama evaluate model yang digunakan untuk mengevaluasi kinerja model machine learning dan menampilkan metrik evaluasinya.
grid_search_results = {}
 for model name, pipeline in pipelines.items():
    grid_search = GridSearchCV(pipeline, param grids[model_name], cv=3, scoring='neg_mean_squared_error', n_jobs=-1)
    grid search.fit(X train, y train)
    grid search results[model name] = grid search
  melakukan hyperparameter tuning pada beberapa model machine learning menggunakan GridSearchCV dan menyimpan hasilnya.
print("Best Polynomial Regression Model:")
evaluate model(grid search results["Polynomial Regression"].best estimator , X test, y test, "Polynomial Regression")
print("Best Decision Tree Model:")
evaluate_model(grid_search_results["Decision Tree"].best_estimator_, X_test, y_test, "Decision Tree")
print("Best k-Nearest Neighbors Model:")
evaluate model(grid_search_results["k-NN"].best_estimator_, X_test, y_test, "k-Nearest_Neighbors")
print("Best XGBoost Model:")
xgb_model_key = list(pipelines.keys())[-1]
evaluate_model(grid_search_results[xgb_model_key].best_estimator_, X_test, y_test, "XGBoost Regression")
 #Evaluasi setiap model dengan parameter terbaik
```

```
Best Polynomial Regression Model:
Polynomial Regression Performance:
Mean Squared Error (MSE): 106.82
Mean Absolute Error (MAE): 7.71
R^2 Score: 0.07
Best Decision Tree Model:
Decision Tree Performance:
Mean Squared Error (MSE): 100.70
Mean Absolute Error (MAE): 7.30
R^2 Score: 0.13
Best k-Nearest Neighbors Model:
k-Nearest Neighbors Performance:
Mean Squared Error (MSE): 106.77
Mean Absolute Error (MAE): 7.65
R^2 Score: 0.07
Best XGBoost Model:
XGBoost Regression Performance:
Mean Squared Error (MSE): 106.77
Mean Absolute Error (MAE): 7.65
R^2 Score: 0.07
(106.77440431845443, 7.648052276027527, 0.07411883675541708)
```

Evaluate Best Model

```
def evaluate_model(y_true, y_pred):
    mse = mean_squared_error(y_true, y_pred)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y_true, y_pred)
    r2 = r2_score(y_true, y_pred)
    return mse, rmse, mae, r2
 #Untuk menghitung dan mengembalikan metrik-metrik evaluasi untuk model machine learning, khususnya untuk model regresi.
poly_pipeline = Pipeline([
    ('poly', PolynomialFeatures()),
    ('scaler', StandardScaler()),
    ('model', LinearRegression())
poly_param_grid = {
     'poly__degree': [2, 3, 4],
    'model__fit_intercept': [True, False]
poly_grid = GridSearchCV(poly_pipeline, poly_param_grid, cv=5, scoring='neg_mean_squared_error')
poly_grid.fit(X_train, y_train)
poly_best_model = poly_grid.best_estimator_
poly_y_pred = poly_best_model.predict(X_test)
poly_mse, poly_rmse, poly_mae, poly_r2 = evaluate_model(y_test, poly y pred)
print("\nBest Polynomial Regression Model Metrics:")
print(f"MSE: {poly_mse:.2f}, RMSE: {poly_rmse:.2f}, MAE: {poly_mae:.2f}, R^2: {poly_r2:.2f}")
#Polynomial Regression
 # Decision Tree
tree_param_grid = {
    'max_depth': [3, 5, 10, None],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
tree_grid = GridSearchCV(DecisionTreeRegressor(random_state=42), tree_param_grid, cv=5, scoring='neg_mean_squared_error')
tree_grid.fit(X_train, y_train)
tree_best_model = tree_grid.best_estimator_
tree_y_pred = tree_best_model.predict(X_test)
tree_mse, tree_rmse, tree_mae, tree_r2 = evaluate_model(y_test, tree_y_pred)
```

Evaluate Best Model

```
print("\nBest Decision Tree Model Metrics:")
print(f"MSE: {tree_mse:.2f}, RMSE: {tree_rmse:.2f}, MAE: {tree_mae:.2f}, R^2: {tree_r2:.2f}")
#Decision Tree
knn param grid = {
    'n_neighbors': [3, 5, 10],
    'weights': ['uniform', 'distance'],
    'metric': ['euclidean', 'manhattan']
knn_grid = GridSearchCV(KNeighborsRegressor(), knn_param_grid, cv=5, scoring='neg_mean_squared_error')
knn grid.fit(X train, y train)
knn_best_model = knn_grid.best_estimator_
knn y pred = knn best model.predict(X test)
knn_mse, knn_rmse, knn_mae, knn_r2 = evaluate_model(y_test, knn_y_pred)
print("\nBest k-Nearest Neighbors Model Metrics:")
print(f"MSE: {knn_mse:.2f}, RMSE: {knn_rmse:.2f}, MAE: {knn_mae:.2f}, R^2: {knn_r2:.2f}")
#K-Nearest Neighbors
xgb param grid = {
    'n_estimators': [50, 100, 200],
    'learning_rate': [0.01, 0.1, 0.2],
    'max_depth': [3, 5, 7],
    'subsample': [0.8, 1.0],
    'colsample_bytree': [0.8, 1.0]
xgb grid = GridSearchCV(XGBRegressor(random state=42, eval metric='rmse'), xgb param grid, cv=5, scoring='neg mean squared error')
xgb_grid.fit(X_train, y_train)
xgb_best_model = xgb_grid.best_estimator_
xgb_y_pred = xgb_best_model.predict(X_test)
xgb_mse, xgb_rmse, xgb_mae, xgb_r2 = evaluate_model(y_test, xgb_y_pred)
print("\nBest XGBoost Model Metrics:")
print(f"MSE: {xgb_mse:.2f}, RMSE: {xgb_rmse:.2f}, MAE: {xgb_mae:.2f}, R^2: {xgb_r2:.2f}")
#XGBoost
```

Evaluate Best Model

```
Best Polynomial Regression Model Metrics:
MSE: 3993471.75, RMSE: 1998.37, MAE: 1998.34, R^2: -34627.90

Best Decision Tree Model Metrics:
MSE: 100.70, RMSE: 10.04, MAE: 7.30, R^2: 0.13
```

Best k-Nearest Neighbors Model Metrics:

MSE: 108.44, RMSE: 10.41, MAE: 7.69, R^2: 0.06

Best XGBoost Model Metrics:

MSE: 93.70, RMSE: 9.68, MAE: 7.00, R^2: 0.19

